Разделительная кластеризация

Формулировка задания

• Разработать программу кластеризации заданного набора данных алгоритмами k-Means и k-Medoids. Параметры программы: набор данных и число кластеров. Результат должен содержать координаты точек, номера кластеров и ошибку кластеризации.

• Провести эксперименты на наборе customers и построить точечные диаграммы принадлежности к кластерам, а также графики зависимости ошибки от k.

• Добавить параметр доли зашумленных объектов и случайное изменение координат выбранной части набора.

• Повторить эксперименты для долей шума 1%, 3%, 5% и 10% при k от 3 до 9, визуализировать и объяснить результаты.

• Подготовить связный PDF-отчёт с формулировкой, ссылкой на каталог репозитория, рисунками и выводами.

Исходные тексты, набор данных, таблицы назначений кластеров, метрики, рисунки находятся в каталоге lab5:

https://github.com/EykoSoul/Lab5.git

Описание исходных признаков

Признак	**Смысл**
Age	возраст, полных лет
Education	целочисленный код образования
YearsEmployed	трудовой стаж, полных лет
Income	доход, тыс. долларов в год
CardDebt	задолженность по карте
OtherDebt	прочая задолженность
Defaulted	признак банкротства: 1 или 0
DebtIncomeRatio	отношение задолженности к доходу

Подготовка данных

В столбце Defaulted отсутствуют 150 значений. Они заменяются медианой столбца. После этого каждый признак стандартизуется: из значения вычитается среднее и результат делится на стандартное отклонение. Стандартизация нужна потому, что Income измеряется десятками и сотнями, а долговые показатели могут быть единицами; без неё признаки с большим численным диапазоном почти полностью определяли бы евклидово расстояние.

z=(x-mean)/std

Внесение шума

Для каждой заданной доли воспроизводимо выбирается соответствующее число объектов: 8, 26, 42 или 85 из 850. У каждого выбранного объекта случайно определяется от одной до восьми координат. К ним добавляются независимые значения из нормального распределения N(0, 3) уже в стандартизованном пространстве. Один и тот же seed 42 обеспечивает повторяемость. На точечных графиках изменённые объекты обведены чёрным контуром.

Такой шум является сильным: стандартное отклонение добавки в три раза превышает стандартное отклонение исходной координаты. Поэтому даже небольшая доля изменённых строк позволяет явно увидеть устойчивость методов.

Алгоритмы и критерии

k-Means

Алгоритм поочерёдно назначает объект ближайшему центроиду и заменяет каждый центроид средним объектов кластера. Использована инициализация k-means++ и 20 независимых стартов; сохраняется решение с наименьшей ошибкой.

k-Medoids

В k-Medoids центр каждого кластера обязан быть реальным объектом набора. После назначения точек ближайшему медоиду новым медоидом становится объект с минимальной суммой расстояний до остальных объектов своего кластера. Инициализация аналогична k-means++, число итераций ограничено 100.

Ошибка и дополнительная оценка

Для сопоставимости методов ошибка определена одинаково как сумма квадратов евклидовых асстояний от каждой точки до назначенного центра. Для k-Means центром является центроид, для k-Medoids - медоид.

SSE = sum(i=1..n) ||x_i - c_cluster(i)||^2

SSE неизбежно не возрастает при увеличении k, поэтому она не определяет оптимальное k сама по себе. Для интерпретации дополнительно вычислен коэффициент силуэта: большее значение означает более компактные и лучше разделённые кластеры.

Эксперимент без шума

Алгоритм	k	SSE	Силуэт	Итераций	Мин. кластер	Макс. кластер
k-Means	3	4339,02	0,287	12	147	537
k-Means	4	3763,03	0,253	11	41	423
k-Means	5	3411,06	0,250	18	40	359
k-Means	6	3102,50	0,245	20	14	338

Алгоритм	k	SSE	Силуэт	Итераций	Мин. кластер	Макс. кластер
k-Means	7	2892,25	0,218	16	12	274
k-Means	8	2697,06	0,230	24	11	279
k-Means	9	2543,01	0,195	26	8	204
k-Medoids	3	5269,01	0,143	2	197	455
k-Medoids	4	4612,07	0,165	3	89	390
k-Medoids	5	3927,33	0,186	5	66	311
k-Medoids	6	3680,14	0,187	4	31	329
k-Medoids	7	3442,90	0,200	5	26	334
k-Medoids	8	3260,95	0,165	5	26	245
k-Medoids	9	3137,09	0,172	5	6	239

У обоих методов SSE монотонно снижается с ростом k, поскольку дополнительные центры уменьшают расстояние до ближайшего представителя. Для k-Means уменьшение наиболее заметно между k=3 и k=4: 4339,0 до 3763,0. Наибольший силуэт k-Means равен 0,287 при k=3. Для k-Medoids максимум силуэта 0,200 достигнут при k=7, но значения в целом ниже.

При одинаковом k ошибка k-Means ниже, чем k-Medoids. Это ожидаемо: среднее арифметическое минимизирует сумму квадратов расстояний, тогда как ограничение центра реальным объектом не позволяет k-Medoids достичь меньшей SSE.

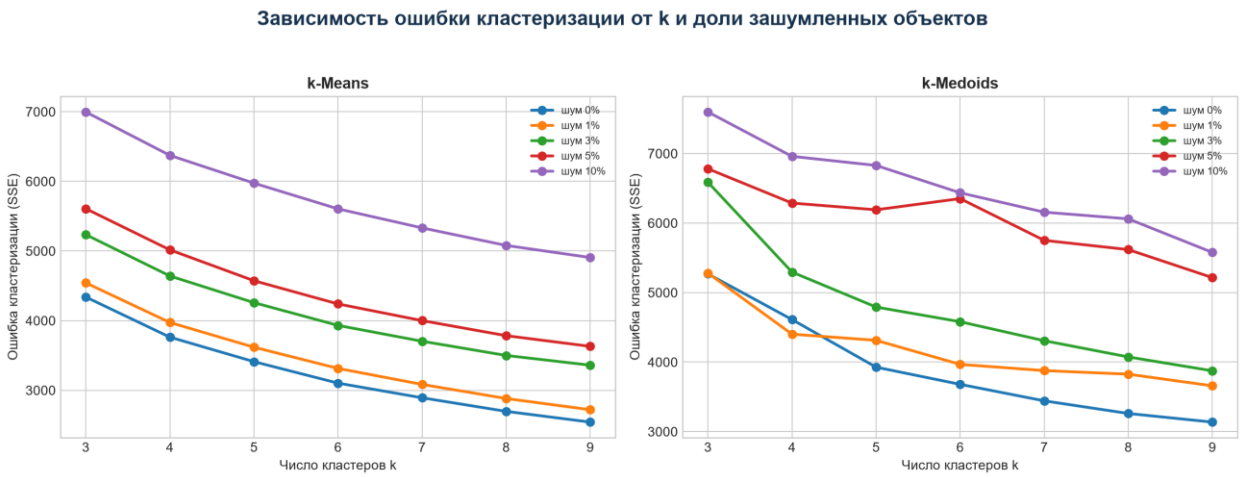


Рисунок 1 - Зависимость SSE от k для обоих алгоритмов и всех долей шума.

Точечная визуализация

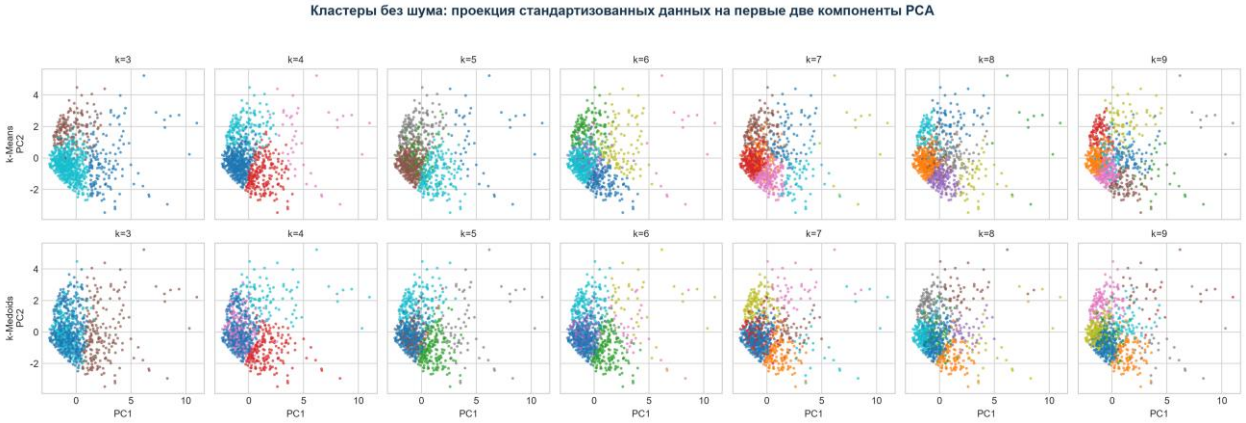


Рисунок 2 - Цвет точки показывает кластер при k от 3 до 9 на данных без шума.

Для рисунка данные спроецированы методом главных компонент (PCA) на плоскость. Цвета отражают результат кластеризации в исходном восьмимерном пространстве, а не повторную кластеризацию двух координат. Поэтому визуально соседние точки иногда имеют разные цвета: часть различий находится в компонентах, не показанных на плоскости.

При малых k k-Means формирует один крупный центральный кластер и несколько групп с более высокими значениями долговых или доходных признаков. С ростом k крупные области дробятся, а минимальный размер кластера уменьшается до 8 объектов при k=9. Это объясняет снижение силуэта: некоторые новые группы описывают локальные или редкие профили, а не хорошо отделённые сегменты.

Эксперимент с шумом

Сравнение при k=5

Шум	Изменено	SSE k-Means	SSE k-Medoids	Δ SSE	Силуэт k-Means	Силуэт k-Medoids	силуэт
0%	0	3411,06	3927,33	+516,26	**0,250**	0,186	−0,064
1%	8	3618,42	4313,31	+694,89	**0,245**	0,148	−0,097
3%	26	4258,61	4791,81	+533,20	**0,236**	0,230	−0,006
5%	42	4573,44	6190,64	+1617,20	**0,228**	0,188	−0,040
10%	85	5974,71	6828,79	+854,08	**0,213**	0,206	−0,007

При k=5 увеличение доли шума от 0% до 10% повышает SSE k-Means с 3411,1 до 5974,7, то есть на 75,2%. Для k-Medoids ошибка возрастает с 3927,3 до 6828,8, на 73,9%. Коэффициент силуэта k-Means снижается с 0,250 до 0,213, что отражает размывание структуры. У k-Medoids силуэт меняется немонотонно, поскольку отдельные выбросы могут становиться маленькими кластерами или медоидами; при 10% шума минимальный кластер содержит один объект.

Нельзя заключать об устойчивости только по абсолютной SSE: k-Medoids оптимизирует сумму обычных расстояний через выбор реальных представителей, а в отчёте для сравнения показана квадратная ошибка. Поэтому одновременно анализируются силуэт, размеры кластеров и визуальная структура.

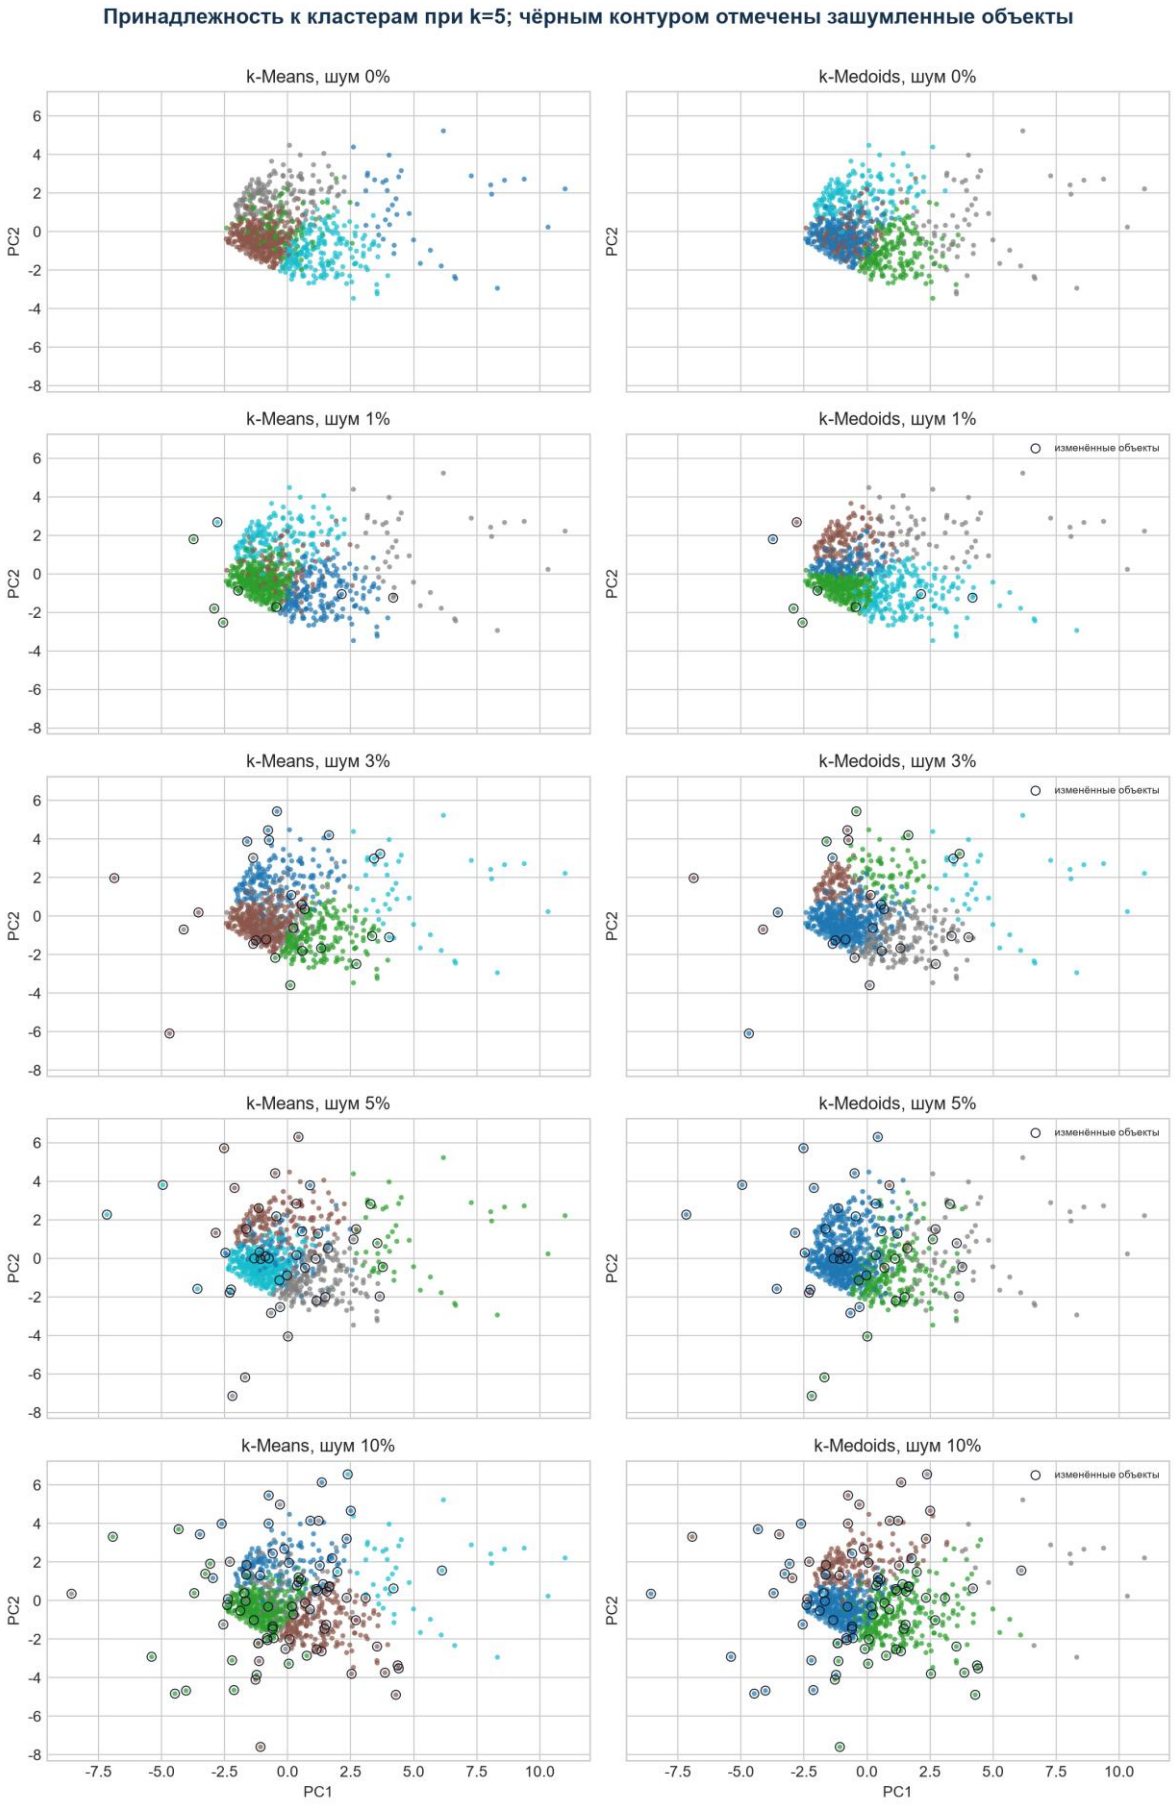


Рисунок 3 - Кластеры при k=5 для всех уровней шума; изменённые объекты обведены чёрным.

Чувствительность к шуму

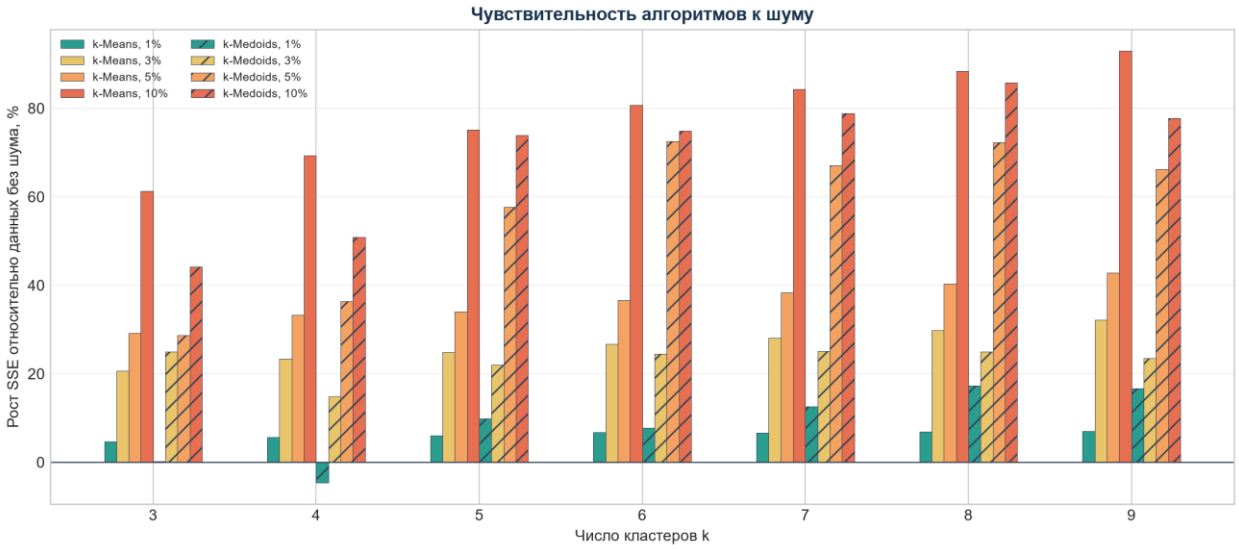


Рисунок 4 - Относительный рост SSE по сравнению с соответствующим запуском без шума

Рост SSE усиливается как с долей шума, так и в большинстве случаев с k. При 10% шума для k-Means относительное увеличение меняется от 61,3% при k=3 до 92,9% при k=9. Для k-Medoids соответствующий диапазон составляет 44,2-85,8%, а при k=9 наблюдается 77,8%. Дополнительные кластеры частично выделяют выбросы в отдельные группы, но оставшаяся неоднородность внутри кластеров продолжает увеличивать квадратную ошибку.

Кривые ошибки на рисунке 1 сохраняют общий нисходящий вид при любом уровне шума. Следовательно, эффект k и эффект шума действуют в противоположных направлениях: большее k уменьшает расстояния до центра, а большее число искажённых объектов увеличивает их. Стабильного единственного локтя для всех сценариев нет.

Выводы

Разработана параметризуемая программа для k-Means и k-Medoids. Она загружает CSV, подготавливает признаки, при необходимости зашумляет заданную долю объектов, сохраняет стандартизованные координаты и назначенные кластеры и выводит SSE, размеры групп, центры или медоиды. Для customers выполнены 70 запусков при k от 3 до 9 и пяти уровнях шума.

На исходных данных k-Means даёт наибольший силуэт 0,287 при k=3. Это наиболее обоснованный выбор, если главным критерием считать разделённость сегментов. Более крупные k уменьшают SSE, но создают малые группы и не улучшают силуэт. k-Medoids имеет более высокую квадратную ошибку, зато его центры являются реальными клиентами и могут быть проще для предметной интерпретации.

Внесение сильного шума закономерно повышает ошибку и визуально создаёт удалённые точки. При k=5 и 10% шума SSE выросла примерно на три четверти у обоих методов. k-Means демонстрирует плавное ухудшение силуэта; k-Medoids иногда выделяет выбросы в очень малые кластеры, поэтому для практического применения полезно контролировать минимальный размер сегмента и повторять запуски с несколькими seed.